

시퀀스 모델

Natural Language Processing (COSE461)

강사:

Buru Chang, Ph.D.

조교수

컴퓨터 과학 및 공학 학과

한국대학교, 서울, 대한민국



클래스 목표

시퀀스 모델 이해

- 시퀀스 태깅 NLP 작업
- 품사 태깅, 개체명 인식
- 히든 마르코프 모델
- 비터비 알고리즘
- MEMM
- CRF

추천 도서

교과서 17.1-17.4

Michael Collins 의 노트

시퀀스 모델이란 무엇인가?

What is Sequence Model

예시

- 품사 태깅


PRP: 개인 대명사, VBZ: 동사, 3rd person singular present, NN: 단수 명사, NNS: 복수 명사, IN: 전치사 또는 종속 접속사, DT: 한정사



예시

- 개체명 인식 (NER)


P: 사람, L: 위치, O: 조직, E: 사건, D: 날짜



Sequence Models

NLP 파이프라인

- NLP 파이프라인



NAME	COMPONENT	CREATES	DESCRIPTION
tokenizer	Tokenizer	Doc	Segment text into tokens.
PROCESSING PIPELINE			
tagger	Tagger	Token.tag	Assign part-of-speech tags.
parser	DependencyParser	Token.head, Token.dep, Doc.sents, Doc.noun_chunks	Assign dependency labels.
ner	EntityRecognizer	Doc.ents, Token.ent_iob, Token.ent_type	Detect and label named entities.
lemmatizer	Lemmatizer	Token.lemma	Assign base forms.
textcat	TextCategorizer	Doc.cats	Assign document labels.
custom	custom components	Doc._.xxx, Token._.xxx, Span._.xxx	Assign custom attributes, methods or properties.

<https://spacy.io/usage/processing-pipelines>

Part-of-speech tags

- 단어 클래스 또는 구문 범주
- 단어(및 그 주변 단어)에 대한 유용한 정보를 드러냄
- 1. The/DT cat/NN sat/VBD on/IN the/DT mat/NN


2. KU/NNP is/VBZ in/IN Seoul/NNP



Sequence Models

Part-of-speech tags


- 서로 다른 단어는 서로 다른 기능을 가집니다
- 대략 두 가지 클래스로 나눌 수 있습니다
- 폐쇄 클래스: 고정된 구성원, 기능 단어
예: 전치사 (in, on, of), 한정사 (the, a)
- 개방 클래스: 새로운 단어가 자주 추가됩니다
예: 명사 (Twitter, Facebook), 동사 (google),
형용사, 부사



Sequence Models

Part-of-speech tags

영어에는 몇 개의 품사 태그가 있다고 생각하십니까?



Part-of-speech tags

펜 트리뱅크 품사 태그 집합

45 태그 (Marcus et al., 1993) based on 월스트리트 저널 (WSJ)

Tag	Description	Example	Tag	Description	Example	Tag	Description	Example
CC	coordinating conjunction	<i>and, but, or</i>	PDT	predeterminer	<i>all, both</i>	VBP	verb non-3sg present	<i>eat</i>
CD	cardinal number	<i>one, two</i>	POS	possessive ending	<i>'s</i>	VBZ	verb 3sg pres	<i>eats</i>
DT	determiner	<i>a, the</i>	PRP	personal pronoun	<i>I, you, he</i>	WDT	wh-determ.	<i>which, that</i>
EX	existential 'there'	<i>there</i>	PRP\$	possess. pronoun	<i>your, one's</i>	WP	wh-pronoun	<i>what, who</i>
FW	foreign word	<i>mea culpa</i>	RB	adverb	<i>quickly</i>	WP\$	wh-possess.	<i>whose</i>
IN	preposition/ subordin-conj	<i>of, in, by</i>	RBR	comparative adverb	<i>faster</i>	WRB	wh-adverb	<i>how, where</i>
JJ	adjective	<i>yellow</i>	RBS	superlatv. adverb	<i>fastest</i>	\$	dollar sign	<i>\$</i>
JJR	comparative adj	<i>bigger</i>	RP	particle	<i>up, off</i>	#	pound sign	<i>#</i>
JJS	superlative adj	<i>wildest</i>	SYM	symbol	<i>+, %, &</i>	"	left quote	<i>' or "</i>
LS	list item marker	<i>1, 2, One</i>	TO	"to"	<i>to</i>	"	right quote	<i>' or "</i>
MD	modal	<i>can, should</i>	UH	interjection	<i>ah, oops</i>	(	left paren	<i>[, (, {, <</i>
NN	sing or mass noun	<i>llama</i>	VB	verb base form	<i>eat</i>	)	right paren	<i>],), }, ></i>
NNS	noun, plural	<i>llamas</i>	VBD	verb past tense	<i>ate</i>	,	comma	<i>,</i>
NNP	proper noun, sing.	<i>IBM</i>	VBG	verb gerund	<i>eating</i>	.	sent-end punc	<i>. ! ?</i>
NNPS	proper noun, plu.	<i>Carolinas</i>	VBN	verb past part.	<i>eaten</i>	:	sent-mid punc	<i>: ; ... - -</i>

Part-of-Speech Tagging

품사 모호함

- 문장의 각 단어에 품사를 태깅한다
- 모호화 작업: 각 단어는 문맥에 따라 다른 기능을 가질 수 있다

The/DT man/NN bought/VBD a/DT boat/NN

같은 단어지만 다른 태그

The/DT old/NN man/VBP the/DT boat/NN

earnings growth took a back/JJ seat

a small building in the back/NN

a clear majority of senators back/VBP the bill

Dave began to back/VB toward the door

enable the country to buy back/RP about debt

I was twenty-one back/RB then

일부 단어는 많은 기능을 가진다

JJ: 형용사, NN: 단일 또는 질량 명사, VBP: 동사, 3 인칭 단수 현재형 제외 VB: 동사, 기본형, RP: 입자, RB: 부사

Part-of-Speech Tagging

품사 모호함

Types:		WSJ	Brown
Unambiguous	(1 tag)	44,432 (86%)	45,799 (85%)
Ambiguous	(2+ tags)	7,025 (14%)	8,050 (15%)
Tokens:			
Unambiguous	(1 tag)	577,421 (45%)	384,349 (33%)
Ambiguous	(2+ tags)	711,780 (55%)	786,646 (67%)

- Types = 코퍼스 내 서로 다른 단어
- Tokens = 코퍼스 내 모든 단어 (반복될 수 있음)

명확한 유형:

Jane NNP

hesitantly RB

Sequence Models

Part-of-Speech Tagging

품사 태깅 성능

- 간단한 기준선

동기: 많은 단어들이 태깅하기 쉬울 수 있음

가장 빈번한 클래스: 학습 데이터에서 각 단어가 가장 많이 등장한 클래스에 할당함. (예: man/NN)

- 이 기준선이 단어 태깅에 얼마나 정확할 것이라고 생각하십니까?

-

Part-of-Speech Tagging

- 간단한 기준선

- 월스트리트 저널(WSJ)에서 단어 토큰의 92.34%를 정확하게 태깅합니다!

최신 성능 ~ 97%

평균 영어 문장 ~ 14 단어

- 문장 수준 정확도: $0.9214 = 31\%$ VS $0.9714 = 65\%$

품사 태깅은 아직 해결되지 않았습니다!

Sequence Models

어떻게 더 잘할 수 있을까요?

- 단어(또는 POS)의 기능은 그 문맥에 따라 달라집니다

The/DT old/JJ man/NN bought/VBP the/DT boat/NN

The/DT old/NN man/VBP the/DT boat/NN

- 특정 품사 조합은 매우 가능성이 낮습니다

<JJ, DT>("good the") 또는 <DT, IN>("the in")

- 개별 단어 대신 전체 문장에 대해 결정을 내리는 것이 더 좋습니다

히든 마르코프 모델

타동사 문장 (3 형식 문장)

주어 + 동사 + 목적어

예) | like apples

Sequence Models

Markov chains

- 다양한 시퀀스의 확률을 모델링하고자 함
- 다음 "상태"가 현재 상태에만 의존한다는 가정을 함

이전에 어디서 본 적이 있는가?

Sequence Models

Markov chains

- 각 상태는 K 개의 값 중 하나를 가질 수 있습니다 (간단히 $\{1, 2, \dots, K\}$ 로 가정할 수 있음)


- 마르코프 가정: $P(s_t | s_1, s_2, \dots, s_{t-1}) = P(s_t | s_{t-1})$

- 마르코프 체인은 다음 요소로 지정됩니다

초기 상태 확률 분포 π , $\pi \in \{1, 2, \dots, K\}$

전이 확률 행렬 ($K \times K$)


$P(s_t | s_{t-1})$: 전이 확률



Sequence Models

Markov chains

- "the dog runs" 시퀀스의 확률은 얼마인가? (Assume $\pi(\text{the}) = 0.8$)




Sequence Models


품사 태깅을 위한 마르코프 체인

- The/DT cat/NN sat /VBD on/IN the/DT mat /NN
- 우리는 상태가 품사 태깅 태그가 되기를 원한다
- 문제: 우리는 일반적으로 텍스트에 나타나는 품사 태깅 태그의 시퀀스를 보지 못한다:

The/?? cat/?? sat/?? on/?? the/?? mat/??




히든 마르코프 모델 (HMM)



- 우리는 일반적으로 텍스트에서 품사 태그의 시퀀스를 보지 못합니다

- 그러나 우리는 단어를 관찰합니다!
- HMM 은 은닉 이벤트와 관측 이벤트를 동시에 추론할 수 있게 해줍니다.
- 각 위치에 단어를 생성하는 태그가 있다고 가정합니다


HMM 의 구성 요소



- 상태 집합 $S = \{1, 2, \dots, K\}$ 및 관측 시퀀스 $O = \{o_1, o_2, \dots, o_n\}, O_i \in V$
- 초기 상태 확률 분포 (π)
- 전이 확률 $P(s_{t+1}|s_t)$
- 방출 확률 $P(o_t|s_t)$

Hidden Markov Chain

가정




- 마르코프 가정:

$$P(s_t | s_1, s_2, \dots, s_{t-1}) = P(s_t | s_{t-1})$$

- 출력 독립성:

$$P(o_t | s_1, s_2, \dots, s_t) \cong P(o_t | s_t)$$

시퀀스 가능도



- 마르코프 가정:


$$\begin{aligned}
 P(S, O) &= P(s_1, s_2, \dots, s_n, o_1, o_2, \dots, o_n) \\
 &= \pi(s_1) p(o_1 | s_1) \prod_{i=2}^n \underbrace{P(s_i | s_{i-1})}_{\text{transition probability}} \underbrace{P(o_i | s_i)}_{\text{emission probability}}
 \end{aligned}$$

- 만약 시작 부분에 더미 상태 $s_0 = \emptyset$ 를 추가한다면,

$$P(S, O) = \prod_{i=1}^n P(s_i | s_{i-1}) P(o_i | s_i) \quad (s_0 = \emptyset)$$

Hidden Markov Chain

예시: 시퀀스 가능성도



Sequence Models

Learning

학습 데이터:

1 Pierre / NNP Vinken / NNP 1/1 61 /CD years / NNS old /JJ ,/, will /MD join /VB the /DT board / NN as /IN a/DT nonexecutive / JJ director /NN Nov. NNP 29 /CD /

2 Mr. /NNP Vinken / NNP is /VBZ chairman /NN of /IN Elsevier /NNP N.V. /NNP ,/, the /DT Dutch /NNP publishing /VBG group / NN /

3 Rudolph /NNP Agnew /NNP 1, 55 /CD years / NNS old / JJ and/CC chairman /NN of /IN Consolidated / NNP Gold / NNP Fields / NNP PLC /NNP / was /VBD named /VBN a /DT nonexecutive / JJ director /NN of /IN this/DT British / JJ industrial / JJ conglomerate / NN ./.

$$P(o|s) = \frac{Count(o, s)}{Count(s)}$$

38,219 It/PRP is /VBZ also /RB pulling /VBG 20 /CD people/ NNS out /IN
of/IN Puerto /NNP Rico / NNP / who /WP were /VBD helping /VBG
Hurricane / NNP Hugo / NNP victims /NNS / and /CC sending /VBG

Q:

them PRP to /TO San 1 NNP Francisco /NNP instead /RB /

- 최대 가능도 추정:

$$P(s_i|s_j) = \frac{Count(s_j, s_i)}{Count(s_j)}$$

추정할 확률 수?

A: 전이 확률 $(K+1) \times K$

방출 확률 $121 \times K$

Sequence Models

학습 예시

- 우리 말뭉치에서:

- 1. The/DT cat/NN sat /VBD on/IN the/DT mat /NN
- 2. KU/ NNP is/VBZ in/IN Seoul/NNP
- 3. The/DT old/NN man/VBP the/DT boat/NN

- 추정값


$$P(NN|DT) = 4/4 \quad P(DT|IN) = 1/2$$

대소문자 구분 여부에 따라

$$P(cat|NN) = 1/4 \quad P(the|DT) = 2/4$$

Decoding with HMMs

문제



- 과제: 관측값 $\llbracket O \rrbracket = \llbracket O_1 \rrbracket, \llbracket O_2 \rrbracket, \dots, \llbracket O_n \rrbracket$ 이 주어졌을 때 상태 $\llbracket S \rrbracket = \llbracket S_1 \rrbracket, \llbracket S_2 \rrbracket, \dots, \llbracket S_n \rrbracket$ 의 가장 가능성 높은 시퀀스를 찾기

$$\llbracket P \rrbracket(\llbracket O \rrbracket | \llbracket S \rrbracket) \llbracket P \rrbracket(\llbracket S \rrbracket)$$

$$\llbracket S \rrbracket = \operatorname{argmax}_{\llbracket s \rrbracket} \llbracket P \rrbracket(\llbracket S \rrbracket | \llbracket O \rrbracket) = \operatorname{argmax}_{\llbracket s \rrbracket}$$

[베이즈 정리]


$$\llbracket P \rrbracket(\llbracket O \rrbracket)$$

$$- \operatorname{argmax}_{\llbracket s_1 \rrbracket, \dots, \llbracket s_n \rrbracket} \prod_{i=1}^n \llbracket P \rrbracket(\llbracket s_i \rrbracket | \llbracket s_{i-1} \rrbracket) \llbracket P \rrbracket(\llbracket o_i \rrbracket | \llbracket s_i \rrbracket)$$


$$= \operatorname{argmax}_{\llbracket s \rrbracket} \llbracket P \rrbracket(\llbracket O \rrbracket | \llbracket S \rrbracket) \llbracket P \rrbracket(\llbracket S \rrbracket) \quad [\llbracket P \rrbracket(\llbracket O \rrbracket) \text{를 제거, 이는 } \llbracket s \rrbracket \text{에 의존하지 않음}]$$

어떻게 이를 최대화할 수 있는가?


모든 상태 시퀀스 탐색?



$$\operatorname{argmax}_s (s_1 = s) P(\text{The} | s) = DT$$



$$\operatorname{argmax}_s P(s | DT) \cdot P(\text{cat} | s) = NN$$



$$\hat{s}_t = \operatorname{argmax}_s P(s | \hat{s}_{t-1}) P(o_t | s)$$

- 매우 효율적이지만 최적이지 않습니다!

동적 프로그래밍을 사용하라

일부 추가 데이터 구조를 유지합니다.

확률 격자 $M[T,K]$ 와 역추적 행렬 $B[T,K]$

T: 시간 단계 수

K: 상태 수

$M[i,j]$ 는 시간 i 에서 상태 j 로 끝나는 가장 가능성 높은 상태 시퀀스의 결합 확률을 저장합니다.

$B[i,j]$ 는 시간 i 에서 태그 j 로 끝나는 가장 가능성 높은 시퀀스에서 시간 $i-1$ 의 태그를 나타냅니다.

Sequence Models

- Recall: we want to compute $S = \operatorname{argmax}_{s_1, \dots, s_n} \prod_{i=1}^n P(o_i | s_i) P(s_i | s_{i-1})$

- Let's first see how we can compute the maximum probability

$$\begin{aligned} & \max_{s_1, \dots, s_n} \prod_{i=1}^n P(o_i | s_i) P(s_i | s_{i-1}) \\ &= \max_{s_1, \dots, s_n} P(o_n | s_n) \cdot P(s_n | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \end{aligned}$$

These are the only terms

that depend on S_1 !

Sequence Models

HMM 을 이용한 디코딩

동기: 비터비 알고리즘

$$\begin{aligned}
 & \max_{s_1, \dots, s_n} \prod_{i=1}^n P(o_i | s_i) P(s_i | s_{i-1}) \\
 &= \max_{s_1, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot P(s_2 | s_1) \cdot P(o_1 | s_1) \cdot P(s_1) \\
 &= \max_{s_2, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1) \cdot P(o_1 | s_1) \cdot P(s_1)
 \end{aligned}$$

Sequence Models

Motivation: Viterbi decoding

$$\begin{aligned}
 & \max_{s_1, \dots, s_n} \prod_{i=1}^n P(o_i | s_i) P(s_i | s_{i-1}) \\
 &= \max_{s_1, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot P(s_2 | s_1) \cdot P(o_1 | s_1) \cdot P(s_1) \quad \text{Define } score_1(s) = P(o_1 | s) \cdot P(s) \\
 &= \max_{s_2, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1) \cdot \boxed{P(o_1 | s_1) \cdot P(s_1)} \\
 &= \max_{s_2, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1) \cdot \text{score}_1(s_1)
 \end{aligned}$$

Decoding with HMMs

Motivation: Viterbi decoding

$$\begin{aligned}
 & \max_{s_1, \dots, s_n} \prod_{i=1}^n P(o_i | s_i) P(s_i | s_{i-1}) \\
 &= \max_{s_1, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot P(s_2 | s_1) \cdot P(o_1 | s_1) \cdot P(s_1) \\
 &= \max_{s_2, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1) \cdot P(o_1 | s_1) \cdot P(s_1) \\
 &= \max_{s_2, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1) \cdot score_1(s_1) \\
 &= \max_{s_3, \dots, s_n} P(o_n | s_n) \cdot P(o_{n-1} | s_{n-1}) \cdot \dots \cdot P(o_3 | s_3) \cdot \boxed{\max_{s_2} P(s_3 | s_2) \cdot P(o_2 | s_2) \cdot \max_{s_1} P(s_2 | s_1)} \cdot score_1(s_1)
 \end{aligned}$$

S2 에만 의존하는 용어들

Decoding with HMMs

- $\max_{s_1, \dots, s_n} P(o_1|s_1)P(s_1|s_0)$
- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot P(s_n|s_{n-1}) \cdot P(s_1)$
- $= \max_{s_1, \dots, s_n}$
- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_1} P(s_2|s_1) \cdot P(s_1)$
- $\max_{s_2, \dots, s_n}$
- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_1} P(s_2|s_1) \cdot \text{score}_1(s_1)$
- $= \max_{s_2, \dots, s_n}$
- $\max_{s_3, \dots, s_n} P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_2} P(s_3|s_2) \cdot P(s_2|s_1) \cdot \max_{s_1} P(s_2|s_1) \cdot \text{score}_1(s_1)$
- $s_3, \dots, s_n$

정의

$$\text{score}_i(s) = \max_{s_{i-1}} P(s_i|s_{i-1}) \cdot P(o_i|s) \cdot \text{score}_{i-1}(s_{i-1})$$

Motivation: Viterbi decoding


$\max_{s_1, \dots, s_n} P(o_1|s_1)P(s_1|s_0)$

- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot P(s_n|s_{n-1}) \cdot P(s_1)$
- $= \max_{s_1, \dots, s_n}$
- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_1} P(s_2|s_1) \cdot P(s_1)$
- $\max_{s_2, \dots, s_n}$
- $P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_2} P(s_3|s_2) \cdot P(s_2|s_1) \cdot \max_{s_1} P(s_2|s_1) \cdot \text{score}_1(s_1)$
- $= \max_{s_2, \dots, s_n}$
- $\max_{s_3, \dots, s_n} P(o_1|s_1) \cdot P(s_1|s_0) \cdot \dots \cdot P(o_n|s_n) \cdot \max_{s_2} P(s_3|s_2) \cdot \text{score}_2(s_2)$
- $s_3, \dots, s_n$

Sequence Models

Decoding with HMMs


Viterbi decoding




Sequence Models

Decoding with HMMs

Viterbi decoding




viterbi decoding



Sequence Models

Viterbi decoding

...



...

이 알고리즘의 시간 복잡도는 무엇인가요?

- (A) $O(n)$

(B) $O(nK)$

정답은 (c)입니다

(c) $O(nK^2)$

- (D) $O(n^2K)$

n = 시간 단계 수

K = 상태 수

k

$M[i,j] = \max_k M[i-1,k]P(s_j|s_k)P(o_i|s_j) \quad 1 \leq k \leq K \quad 1 \leq i \leq n$

Sequence Models

Viterbi decoding

- Backward:

Pick max $M[n, k]$ and backtrack using B

k

- In practice, we maximize sum of log probabilities (or minimize the sum of negative log probabilities) instead of maximize the product of probabilities


$$M[2, NN] = \max_k \{M[1, k] P(NN|k) P(cat|NN)\}$$

k

$$M[2, NN] =$$

$$\max_k \{M[1, k] + \log P(NN|k) + \log P(cat|NN)\}$$


k



예시: 비터비 디코딩

- "the cat runs"라는 구문에 대한 태그를 계산하고자 한다고 가정하자

- We need to compute the M and B matrices



	DT	NN	VB
ϕ	0.5	0.3	0.2
DT	0.1	0.5	0.4
NN	0.2	0.3	0.5
VB	0.4	0.3	0.3


	the	cat	runs
DT	0.4	0.5	0.1
NN	0.5	0.4	0.1
VB	0.2	0.3	0.5


동기: 빔 탐색

- K(가능한 은닉 상태 수)가 너무 크면 비터비 알고리즘이 너무 비싸다
- 관측: 많은 경로의 가능도가 매우 낮다

...

...





$O(nK^2)$

Sequence Models

- 각 시점에서 고정된 수의 가설을 유지
- 빔 너비,

DT

score = -0.1

NN

score = -9.8

= 2

VBD

score = -0.7

IN

score □ -10.1

the


log probabilities

- 고정된 수의 가설을 각 지점에서 유지

- 빔 너비,

= 2

단계 1: 현재 빔의 모든 부분 시퀀스 확장




누적 점수

- 빔 너비,

= 2

단계 2: 상위 점수로 되돌리기 (정렬 및 선택) .. 반복!




누적 점수

Decoding with HMMs

Beam search

= 2



- What is the time complexity of this algorithm?

n = number of timesteps

K = number of states

β = beam width

A: $O(nK\beta)$

Pick $\max_k M[n, k]$ from within beam and backtrack

Natural Language Processing (CS548)

Natural Language Processing

Sequence Models

Decoding with HMMs

Beam search

- K(상태 수)가 너무 크면 비터비 알고리즘은 너무 비싸다
-
- 계산 절약을 위해 일부 정확도를 희생하는 절충
- 최종 언급: 빔 탐색은 모든 언어 생성 작업(예: n-그램 LM, GPT-3)에 대한 일반적인 디코딩 방법이다

Sequence Models

삼중항 은닉 마르코프 모델

- 지금까지 본 것은 또한 이중항 HMM 입니다
- 삼중항, 4-그램 등으로 확장할 수 있습니다.

$$P(S,O) = \prod_{i=1}^n P(s_i | s_{i-1}, s_{i-2}) P(o_i | s_i)$$

$$\text{Count}(s_i, s_{i-1}, s_{i-2})$$

- MLE 추정: $P(s_i | s_{i-1}, s_{i-2})$

$$\text{Count}(s_{i-1}, s_{i-2})$$

- 비터비: $M[i, j, k] = \max_r M[i-1, k, r] P(s_j | s_k, s_r) P(o_i | s_j)$ $1 \leq j, k, r \leq K$ $1 \leq i \leq n$

r

시간 i 에 상태 j 로 끝나고 시간 i-1 에 상태 k 로 끝나는 가장 가능성 높은 상태 시퀀스

시간 복잡도: $O(nK^3)$


최대 엔트로피 마르코프 모델 (MEMM)

ICML 2000


동기: MEMM

- $P(S_1, \dots, s_n | O_1, \dots, O_n)$ 을 직접 모델링할 수 있는가?

,




히든 마르코프 모델



MEMM

MEMM 정의



$$P(S|O) = \prod_{i=1}^n P(s_i | s_{i-1}, s_{i-2}, \dots, s_1, 0) \quad 0 = \langle 0_1, 0_2, \dots, 0_n \rangle$$

= $\prod_{i=1}^n P(s_i | s_{i-1}, 0)$ 마르코프 가정: 빅램 MEMM

$P(s_i = S | s_{i-1}, 0) = \exp(w \cdot f(s_i = S, s_{i-1}, 0, i))$ 중요: 전체 단어 시퀀스 O 에 대해 피처를 정의할 수 있음

가중치 피쳐

Maximum Entropy Markov Models

MEMM 정의

- 특징과 가중치를 사용: $P(s_i = S | s_{i-1}, 0) = \exp(w \cdot f(s_i = S, s_{i-1}, 0, i))$

- 다음 중 이 확률을 계산하는 올바른 방법은 무엇인가?

•

• $\exp(w \cdot f(s_i = s, s_{i-1}, 0, i))$

• (A) $P(s_i = S | s_{i-1}, 0)$

• $s' = 1 \exp(w \cdot f(s_i = s, s_{i-1} = s', 0, i))$

$\exp(w \cdot f(s_i = s, s_{i-1}, 0, i))$

(B) $P(s_i = S | s_{i-1}, 0)$

$s' = 1 \exp(w \cdot f(s_i = s', s_{i-1}, 0, i))$

$$\exp(\mathbf{w} \cdot \mathbf{f}(s_i = s, s_{i-1}, 0, i))$$

$$(c) P(S_i = s | S_{i-1}, 0)$$

$$s \neq 1 \exp(\mathbf{w} \cdot \mathbf{f}(s_i = s, s_{i-1}, 0, i))$$

•

Trigram MEMM

$$P(s_i = s | s_{i-1}, 0) = \frac{\exp(\mathbf{w} \cdot \mathbf{f}(s_i = s, s_{i-1}, 0, i))}{\sum_{s'=1}^K \exp(\mathbf{w} \cdot \mathbf{f}(s_i = s', s_{i-1}, 0, i))}$$

- Can be easily extended to trigram MEMM, 4-gram MEMM...

$$P(s_i = s | s_{i-1}, s_{i-2}, 0) = \frac{\exp(\mathbf{w} \cdot \mathbf{f}(s_i = s, s_{i-1}, s_{i-2}, 0, i))}{\sum_{s'=1}^K \exp(\mathbf{w} \cdot \mathbf{f}(s_i = s', s_{i-1}, s_{i-2}, 0, i))}$$

Sequence Models

Maximum Entropy Markov Models

특징을 어떻게 정의하나요?

- 특징 템플릿 $\mathbf{f}(s_i = s', s_{i-1}, s_{i-2}, 0, i)$


$$\langle s_i, o_{i-2} \rangle, \langle s_i, o_{i-1} \rangle, \langle s_i, o_i \rangle, \langle s_i, o_{i+1} \rangle, \langle s_i, o_{i+2} \rangle, \langle s_i, s_{i-1} \rangle, \langle s_i, s_{i-1}, s_{i-2} \rangle$$

- 특징 (이진)

$s_i = VB$ and $o_{i-2} = Janet$

$s_i = VB$ and $o_{i-1} = will$

$s_i = VB$ and $s_{i-1} = MD$



...

- 예시


1, $O_i = \text{'back'}$ and $S_{i-1} = MD$

$f :=$

0, otherwise


Maximum Entropy Markov Models

$$S = \operatorname{argmax}_S P(S|O) = \operatorname{argmax}_S P(s_i | s_{i-1}, O)$$




$$S1 = \operatorname{argmax}_s P(s_i = s_0, O) = \operatorname{argmax}_s W \cdot f(s_i = S, S_{i-1} = , O) = DT$$

Maximum Entropy Markov Models




$$S2 = \operatorname{argmax}_s P(s_i = s | DT, O) = NN$$

Maximum Entropy Markov Models



$$\operatorname{argmax}_s P(s_i = s | i-1, o)$$

- MEMM 에 대한 비터비 디코딩



$$M[i,j] = \max_k M[i-1,k] P(s_i = j | s_{i-1} = k, 0) \quad 1 \leq k \leq K \quad 1 \leq i \leq n$$

k

Backward: pick max $M[n, k]$ and backtrack using B

k

Maximum Entropy Markov Models

- MEMM의 비터비 디코딩과 바이그램 HMM의 디코딩의 계산 복잡도를 어떻게 비교할 수 있습니까?

- (A) HEMM에서 더 많은 연산
- (B) HMM에서 더 많은 연산
- (c) 동일
- (D) MEMM의 특성 수에 따라 달라짐

$$\text{MEMM: } M[i,j] = \max_k M[i-1,k] P(s_i = j | s_{i-1} = k, 0) \quad 1 \leq k \leq K \quad 1 \leq i \leq n$$

k

$$\text{HMM: } M[i,j] = \max_k M[i-1,k] P(s_{i,j}) P(o_{i,j}) \quad 1 \leq k \leq K \quad 1 \leq i \leq n$$

k

Maximum Entropy Markov Models

- 경사 하강법: 로지스틱 회귀와 유사함

$$P(s_i = s | s_{i-1}, O) = \frac{\exp(\mathbf{w} \cdot \mathbf{f}(s_i = s, s_{i-1}, O, i))}{\sum_{s'} \exp(\mathbf{w} \cdot \mathbf{f}(s_i = s', s_{i-1}, O, i))}$$

- 주어진 것: (S,O)의 주석이 달린 쌍, 여기서 각 $S = \langle s_1, s_2, \dots, s_n \rangle$

한 시퀀스에 대한 손실, $L = - \sum_{i=1}^n \log P(s_i | s_{i-1}, O)$

- 가중치 w 에 대한 기울기를 계산하고 업데이트

- HMM 은 결합 $P(S, O)$ 를 모델링하고 MEMM 은 필요한 예측 $P(S|O)$ 를 모델링합니다

- MEMM 은 더 높은 표현력을 가집니다

인접한 상태 간의 의존성과 전체 관측 시퀀스를 고려합니다

더 유연한 특징을 허용합니다

- 데이터셋이 작을 경우 HMM 이 이점을 가질 수 있습니다

조건부 랜덤 필드 (CRF)

ICML 2001

Sequence Models


소개

- 모델 $P(s_1, \dots, s_n | o_1, \dots, o_n)$ 을 직접

,

- 마르코프 가정 없음

$$P(S|O) = \frac{\exp(\mathbf{w} \cdot \mathbf{f}(S, O))}{\sum_{S'} \exp(\mathbf{w} \cdot \mathbf{f}(S', O))} = \frac{\exp(\mathbf{w} \cdot \mathbf{f}(S, O))}{Z(O)}$$



상태 S 와 관측 O 의 전체 시퀀스를 전역 특성 벡터에 매핑

- 전체 시퀀스에 대해 정규화

Sequence Models

특징

- 각 F_k 는 f 의 전역 특징 함수입니다

$m \sum_{k=1}^m F_k(S, O)$

$\exp \left(\sum_{k=1}^m w_k \cdot F_k(S, O) \right)$


$P(S|O)$

$m \sum_{k=1}^m F_k(S', O)$

$\sum_{S'} \exp \left(\sum_{k=1}^m w_k \cdot F_k(S', O) \right)$

- 이전 및 현재 상태에만 의존하는

지역 특징의 조합으로 계산될 수 있습니다



- 각 지역 특징은
이전 및 현재 상태에만 의존합니다

Sequence Models

조건부 랜덤 필드

디코딩

- $S = \operatorname{argmax}_S P(S|O)$

$\exp(w \cdot f(S, O))$

argmax_S

$Z(O)$

- $= \operatorname{argmax}_S \exp(w \cdot f(S, 0))$
- $= \operatorname{argmax}_S \sum_{k=1} \sum_{i=1} W_k f_k(S_{i-1}, S_i, 0, i)$

- Use Viterbi similar to HMM and MEMM

Sequence Models

- $P(S|O)$

$\exp(\sum_{k=1}^m \sum_{i=1}^n w_k f_k(s_{i-1}, s_i, 0, i))$

$Z(O)$

$$= \frac{\exp(\sum_{k=1}^m \sum_{i=1}^n w_k f_k(s_{i-1}, s_i, 0, i))}{\sum_{s'_1, \dots, s'_n} \exp(\sum_{k=1}^m \sum_{i=1}^n w_k f_k(s'_{i-1}, s'_i, 0, i))}$$

$-\log P(S|O) = -\sum_{k=1}^m \sum_{i=1}^n W_k f_k(S_{i-1}, S_i, 0, i) + \log \sum_{s'_1, \dots, s'_n} \exp(\sum_{k=1}^m \sum_{i=1}^n W_k f_k(s'_{i-1}, s'_i, 0, i))$

a $\log p(S|O)$

can be done efficiently using 동적 프로그래밍

awk

Sequence Models

MEMM 과 비교

MEMM 은 마르코프 가정을 사용하여 필요한 예측 $P(S|O)$ 를 모델링하고, CRF 는 그렇지 않습니다.

CRF 는 전역 특징을 사용하는 반면 MEMM 특징은 지역화됩니다.

특징 설계는 두 모델 모두에서 유연합니다.

CRF 는 계산적으로 더 복잡합니다.

CRF 의 역사

- 2000 년대에 매우 인기 있었음

- 다양한 응용 분야:

정보 추출

요약

이미지 라벨링/분할

Sequence Models

- 신경 표현 위에 CRF 사용 (특징과 가중치 대신)

딥러닝 시대의 CRF

-

- 특징 정의 없이 공동 시퀀스 예측

-

- 어텐션이 있는 seq2seq 또는 Transformer 와 같은 최신 아키텍처는 암묵적으로 작업을 수행할 수 있음

E.O.D